具體語言與抽象語言：以邏輯迴歸分類中文小說句子

引言

本研究探問小說句子較多呈現可感知場景，或概念、心理、價值與評價。具體性可能影響讀者對人物、空間、情緒及事件節奏的想像；量化句子分佈可作為探討「故事形狀」與細讀的輔助，但不能取代文學詮釋。

具體與抽象並非互斥，對話可同時包含動作與評價，場景也可能透過象徵承載概念。因此分類器只是可重跑的輔助工具，預測不等同文學解釋。選擇這個二元問題的另一個理由是它的可檢驗性：具體與抽象的判斷標準可以寫成明確的標註規則，讓標籤的產生過程可以被審計，而不是依賴難以重現的直覺。

標籤與資料

concrete
定義為句子主要指涉可感知的物件、動作、地點、人物，或讀者可以直接想像的場景；abstract 則指句子主要談論概念、價值、關係、心理狀態或評價，且缺少明確的感官指涉。這是操作性定義，判斷單位是以句末標點切出的單一句子，不是整段或整篇的主題。當一句同時出現例如人物動作與價值判斷時，標註規則以線索詞數量較多的一側決定，未對句中各分句加權，也未由人工先判定主從焦點。

訓練語料擴充為魯迅《吶喊》全部 14 篇，分析文本為不同作者郁達夫〈秋河〉。最初五篇的抽象初標僅 131 句，未達每類 200 句；全集版切句、清洗及去重後共 2,394 句（篇目分佈見候選資料）。初標為 concrete 1,579、abstract 450、uncertain 365（15.25%）。完成 203 句人工複核並套用 35 個修正後，排除 uncertain，再以 random_state=42 從兩類各抽 400 句，平衡集共 800 句。原作通常屬公有領域；數位版本來源鏈未能核實。

雖然資料檔與欄位沿用早期的 ai_labels.csv、ai_label 命名，初始標註實際上是本機、可重現的規則式關鍵詞法，不是大型語言模型，也不呼叫外部 API。腳本分別計算抽象與具體線索詞在句中的出現次數，較多者成為初始標籤。平手時，含引號的句子按規則暫列為具體；若沒有引號，則以人稱代詞佔句長至少 3% 作為抽象線索，仍無法裁決時記為 uncertain。這種決策規則便於審計，但假設詞語與標籤之間存在穩定對應，且容易忽略否定、反諷、引語立場及一詞多義。規則中的「有引號即具體」只是一項方便的決勝條件，並非語言學上有充分依據的普遍結論。

正文切分字數為〈狂人日記〉5,227、〈孔乙己〉2,634、〈藥〉4,733、〈明天〉3,466、〈一件小事〉1,061、〈頭髮的故事〉2,436、〈風波〉4,421、〈故鄉〉5,145、〈阿Q正傳〉22,155、〈端午節〉4,461、〈白光〉2,962、〈兔和貓〉2,536、〈鴨的喜劇〉1,629、〈社戲〉5,506。〈一件小事〉與〈阿Q正傳〉超出其他篇目的自然篇幅，但本研究保留原文全文，不以截斷或補字調整；候選句仍按 5–120 字過濾。切句、長度篩選及跨篇精確去重後，共取得 2,394 句候選句。

排除 uncertain 後的複核母體為 2,029 句，分層抽查 203 句（規則標籤 concrete 158、abstract 45），涵蓋非 uncertain 母體約 10%。人工判斷與規則標籤一致 168 句，不一致 35 句，一致率為

82.76%，低於 85% 參考門檻。分歧可見規則只憑抽象詞推斷整句的錯誤，例如「吓，什么都瞒不过我。」規則判 abstract，人工依對話情境判 concrete；「华大妈候他喘气平静，才轻轻地给他盖上了满幅补丁的夹被。」規則判 abstract，人工依具體動作判 concrete。反向錯誤如「我诅咒吃人的人，先从他起头；」規則判 concrete，人工視「吃人」為象徵概念而判 abstract。35 個人工修正標籤已在平衡抽樣前套用；一致率偏低表示其餘未複核的規則標籤仍需謹慎看待。

整體標註流程由兩個腳本和一個人工複核步驟串接：scripts/03_ai_label.py 產生規則標註與複核表，並在重跑時保留已填寫的人工複核結果；人工在 data/manual_check.csv 填入 my_label 後，scripts/03b_balance_sample.py 先把複核修正套回全量標註，再從兩類各抽 400 句組成平衡樣本。這個設計讓「規則初標 → 人工複核 → 套用修正 → 平衡抽樣」每一步都有對應的資料檔與程式，任何人依 README 的順序執行都能重建相同的訓練集。

方法

所有文本以 UTF-8 讀取。分篇程式依標題行定位小說，再以正文起始語句避開篇名前的編者介紹，並在正文分隔符截斷後記錄字數。句子使用 (?<=[。！？；]) 切分，保留句末標點；移除純標點句、含明顯非正文標記的句子，以及長度少於 5 或大於 120 字的句子，最後精確去重。data/candidates.csv 保存每句的識別碼、篇名與文本；data/ai_labels.csv 保存初始規則標籤與兩類線索詞數。所有 CSV 使用 UTF-8-SIG，便於以試算表軟體開啟。

800 句平衡資料以 train_test_split(test_size=0.2, stratify=label, random_state=42) 分割，train 為 640 句（各類 320），test 為 160 句（各類 80）。比較三種特徵：A 為 CountVectorizer(max_features=200)；B 為原始詞彙 TF-IDF（max_features=2000, ngram_range=(1,2)）；C 為字元 TF-IDF（analyzer="char", ngram_range=(2,5), max_features=10000）。三者皆接 LogisticRegression(max_iter=1000, random_state=42)。字元特徵直接利用漢字片段，不依賴中文斷詞，另記錄每筆向量是否非零，以檢驗特徵覆蓋。三組特徵對應課程討論的「最常見詞頻、TF-IDF 與標準化」的不同組合，其中字元 n-gram 是針對中文無空格特性的調整。

資料檢查、模型結果與應用狀態

模型 A accuracy 為 0.4938，混淆矩陣（列真值、欄預測；concrete / abstract）為 [[1, 79], [2, 78]]，macro P/R/F1 為 0.4151 / 0.4937 / 0.3412。原始詞彙 TF-IDF 模型 B accuracy 為 0.5125，矩陣 [[80, 0], [78, 2]]，macro P/R/F1 為 0.7532 / 0.5125 / 0.3605。字元 TF-IDF 模型 C accuracy 為 0.7562，矩陣 `[[58, 22], [17, 63]]；concrete P/R/F1 為 0.7733 / 0.7250 / 0.7484，abstract 為 0.7412 / 0.7875 / 0.7636，macro 為 0.7573 / 0.7562 / 0.7560。C 在訓練集 639/640、測試集 159/160 句有非零特徵，詞彙 TF-IDF 僅 548/640、7/160。C 的錯分數為 39/160，其中「他去得本很早，一见榜，便先在这上面寻陈字。」被判 concrete（規則 abstract

，0.5433 / 0.4567），「而且有一匹还成了爱罗先珂君在北京所作唯一的小说《小鸡的悲剧》里的主人公。」被判 abstract（規則 concrete，0.4508 / 0.5492），「我也是人，他们想要吃我了！」也被判 abstract（0.4334 / 0.5666）。字元特徵改善覆蓋與結果，但對話、敘述視角和混合語意仍難判，且測試標籤仍非人工金標。

相對詞彙模型，字元模型降低未匹配特徵的比例，accuracy 達 0.7562，兩類表現較均衡。錯誤呈現多種模式：短句可能依敘事語境而非表面詞彙判斷；「我也是人，他们想要吃我了！」包含具體事件與象徵性恐懼，規則及模型可能分別著重不同層次；描述人物 / 物件的長句也可能因附帶評價而被判為抽象。由於人工一致率只有 82.76%，這些錯誤分析應視為對標註和模型共同偏誤的檢視，而非僅歸因於分類器。

字元模型在〈秋河〉111 句中預測 abstract 67 句（60.36%）、concrete 44 句（39.64%）。prob_concrete 平均 0.4896、中位數 0.4906；105 句（94.59%）落在 0.4–0.6。99/111 句有非零特徵，較詞彙模型的零覆蓋有改善，但多數機率靠近決策邊界，模型判斷仍不穩。例句「東面靠牆，在牀與窗口桌子之間，有一個衣廚……」被預測 abstract（prob_concrete 0.4990）；「但她覺得這些男人，都不過是肉做的機械。」被預測 concrete（0.5275）；帶有場景與感覺的「那少年睡在牀上，向窗外望去……晴爽的秋氣。」被預測 concrete（0.5406）。〈秋河〉沒有人工金標，無法計算正確率或判定跨作者表現是否低於測試集；這些案例是人工覆核候選，不應稱為模型確定的正誤。

限制與改進

本研究雖將訓練池擴為全部 14 篇，仍只包含魯迅一位作者。風格極端篇目可能造成篇目線索：〈狂人日記〉常以心理、觀念與象徵語言推進，〈社戲〉包含豐富場景敘寫，〈阿Q正傳〉以 22,155 字遠長於其他篇目，模型可能利用篇目專屬詞彙與標籤比例，學到「句子像哪一篇」而不是抽象性本身。由於採句子隨機切分，同篇句子可同時進入 train 與 test，篇目線索亦可能造成評估洩漏；更嚴格驗證應按篇目或作者分組留出。字元 n-gram 解決了大部分詞彙零覆蓋，但不排除篇目線索；〈秋河〉特徵覆蓋改善也不代表跨作者效能已獲驗證。

另受規則詞表忽略語境、多義詞與否定所限，二元標籤也無法表達混合句。本次人工一致率 82.76% 低於 85%，顯示應改進詞表並增加抽查；後續可採雙人標註、LLM 輔助後人工核對、中文分詞或字元 n-gram，並比較 BERT 類模型。應按篇目或作者隔離測試。〈秋河〉尚無人工金標，預測分佈只供探索，須另行人工標註才能估計跨作者表現。

綜合而言，這個分類器在測試集上達到 0.7562 的準確率，說明規則產生的標籤中確實存在可被統計模型捕捉的語言訊號；但 82.76% 的標註一致率與 94.59% 的邊界機率提醒我們，這個訊號同時包含規則偏誤與篇目線索。模型最有價值的地方不是給出標籤，而是把「哪些句子難以判斷」具體化為可檢視的清單，讓細讀可以從這些邊界案例開始。