具體語言與抽象語言：以邏輯迴歸分類中文小說句子

引言

我想探問的是：小說句子主要讓人看見一個場景，還是在談概念、心理、價值與評價？這種差異可能影響讀者對人物、空間和事件節奏的想像，因此我嘗試用分類器整理句子的分佈，看看它能否為細讀提供線索。不過，把句子分成兩類只是研究上的方便；它不能代替讀者對文學作品的解讀。

這個題目也有一個麻煩：具體與抽象經常同時出現在一句話裡。人物做了一個具體動作，可能正是在表達抽象的恐懼；場景也可能帶有象徵意味。我仍選擇二分類，是因為標準可以寫成規則、流程也能重跑，但這不代表句子本來就有清楚而唯一的答案。後文的結果需要放在這個前提下理解。

標籤與資料

concrete
定義為句子主要指涉可感知的物件、動作、地點、人物，或讀者可以直接想像的場景；abstract 則指句子主要談論概念、價值、關係、心理狀態或評價，且缺少明確的感官指涉。這是為了本研究而設的操作性定義；判斷單位是按句末標點切出的句子，而不是整段或整篇的主題。同一句若同時有動作與價值判斷，規則只比較線索詞數量，沒有判斷哪個分句才是重點。這讓標註比較容易重做，代價是某些句子會被硬塞進一個標籤。

訓練語料是魯迅《吶喊》全部 14
篇，另外用不同作者郁達夫的〈秋河〉觀察模型如何套用到新文本。最初只用五篇時，規則標出的 abstract 只有 131 句，不足以建立每類至少 200
句的樣本，因此我改用全集。切句、清洗及去重後共有 2,394 句：concrete 1,579、abstract 450、uncertain 365（15.25%）。人工抽查 203 句後，我修正了其中 35 句，再排除 uncertain，從兩類各抽 400 句作平衡樣本。平衡抽樣方便比較模型，但也改變了原始資料的類別比例；所以模型預測的比例不能直接當作小說中兩類句子的真實比例。原作通常屬公有領域，但我未能核實所用數位版本的來源鏈。

資料檔沿用早期的 ai_labels.csv、ai_label 名稱，容易讓人以為標籤由 AI
產生；實際上，初標是本機執行的關鍵詞規則，沒有使用大型語言模型或外部
API。規則比較兩類線索詞的數量；平手時，有引號便暫列
concrete，沒有引號則看人稱代詞是否佔句長至少 3%，仍無法決定就標為 uncertain。這樣做的好處是別人可以檢查每個決定是怎樣來的，問題則是規則把詞語當成相對固定的線索，容易漏掉否定、反諷、引語立場和一詞多義。尤其「有引號就算具體」只是我採用的決勝方法，沒有充分理由把它當成普遍的語言規律。

正文切分字數為〈狂人日記〉5,227、〈孔乙己〉2,634、〈藥〉4,733、〈明天〉3,466、〈一件小事〉1,061、〈頭髮的故事〉2,436、〈風波〉4,421、〈故鄉〉5,145、〈阿Q正傳〉22,155、〈端午節〉4,461、〈白光〉2,962、〈兔和貓〉2,536、〈鴨的喜劇〉1,629、〈社戲〉5,506。〈一件小事〉與〈阿Q正傳〉超出其他篇目的自然篇幅，但本研究保留原文全文，不以截斷或補字調整；候選句仍按 5–120 字過濾。切句、長度篩選及跨篇精確去重後，共取得 2,394 句候選句。

排除 uncertain 後共有 2,029 句，我按標籤分層抽查 203
句，約佔十分之一。人工判斷與規則一致的有 168 句，不一致 35 句，一致率
82.76%，低於本研究採用的 85%
參考門檻。分歧不是單純的錯字或例外：「吓，什么都瞒不过我。」被規則判為 abstract，但放回對話情境，我會把它看成具體的說話行為；「华大妈候他喘气平静，才轻轻地给他盖上了满幅补丁的夹被。」有明確動作，卻被規則判為 abstract。反過來，「我诅咒吃人的人，先从他起头；」雖有「吃人」這個動作詞，語境中的象徵意味更強，我因此判為
abstract。這些例子讓我覺得，規則的一致性不等於判斷本身可靠。35
個修正已套用到平衡樣本，但其餘句子沒有逐一複核，仍可能帶著同樣的偏差。

流程由規則初標、人工複核和抽樣組成：scripts/03_ai_label.py
產生標籤與複核表，scripts/03b_balance_sample.py 則先套用複核結果，再抽出平衡樣本。這讓流程可以重跑，也保留了人工修改的紀錄。不過，可重現只回答「同樣步驟能否得到同樣資料」，不會自動解決「標籤是否準確」這個問題。

方法

所有文本以 UTF-8 讀取。分篇程式依標題行定位小說，再以正文起始語句避開篇名前的編者介紹，並在正文分隔符截斷後記錄字數。句子使用 (?<=[。！？；])
切分，保留句末標點；移除純標點句、含明顯非正文標記的句子，以及長度少於 5 或大於 120
字的句子，最後精確去重。data/candidates.csv
保存每句的識別碼、篇名與文本；data/ai_labels.csv 保存初始規則標籤與兩類線索詞數。所有 CSV 使用 UTF-8-SIG，便於以試算表軟體開啟。

800 句平衡資料以 train_test_split(test_size=0.2, stratify=label, random_state=42) 分割，train 為 640 句（各類 320），test 為 160 句（各類 80）。比較三種特徵：A 為 CountVectorizer(max_features=200)；B 為原始詞彙 TF-IDF（max_features=2000, ngram_range=(1,2)）；C 為字元 TF-IDF（analyzer="char", ngram_range=(2,5), max_features=10000）。三者皆接 LogisticRegression(max_iter=1000, random_state=42)。字元特徵直接利用漢字片段，不依賴中文斷詞，另記錄每筆向量是否非零，以檢驗特徵覆蓋。三組特徵對應課程討論的「最常見詞頻、TF-IDF 與標準化」的不同組合，其中字元 n-gram
是針對中文無空格特性的調整。

資料檢查、模型結果與應用狀態

三個模型的測試結果如下。混淆矩陣的列是真值、欄是預測，類別順序為 concrete、abstract。

模型 A（詞頻）：accuracy 0.4938，macro P/R/F1 為 0.4151 / 0.4937 / 0.3412，混淆矩陣為 [[1, 79], [2, 78]]。

模型 B（詞彙 TF-IDF）：accuracy 0.5125，macro P/R/F1 為
0.7532 / 0.5125 / 0.3605，混淆矩陣為 [[80, 0], [78, 2]]。

模型 C（字元 TF-IDF）：accuracy 0.7562，macro P/R/F1 為
0.7573 / 0.7562 / 0.7560，混淆矩陣為 [[58, 22], [17, 63]]。

模型 C 的 concrete P/R/F1 為 0.7733 / 0.7250 / 0.7484，abstract 為 0.7412 / 0.7875 / 0.7636。它在訓練集有 639/640 句、測試集有 159/160 句非零特徵；詞彙 TF-IDF 則分別只有 548/640 和 7/160。C 錯分 39/160 句，例如把「他去得本很早，一见榜，便先在这上面寻陈字。」判為 concrete（規則標籤是 abstract，兩類機率為 0.5433 / 0.4567），把「而且有一匹还成了爱罗先珂君在北京所作唯一的小说《小鸡的悲剧》里的主人公。」判為 abstract（規則標籤是 concrete，機率為 0.4508 / 0.5492）。「我也是人，他们想要吃我了！」也被判為 abstract（0.4334 / 0.5666）。這些例子說明字元特徵提升了覆蓋率，卻沒有讓模型免於語境、敘述視角和混合語意造成的困難；測試標籤也不是人工金標。

字元模型比詞彙模型少了很多沒有對應特徵的句子，accuracy 也提高到 0.7562，兩類的表現較平衡。但我不會把這個分數直接解讀成模型已經懂得「具體」和「抽象」：測試集的標籤仍主要來自關鍵詞規則，模型可能只是更有效地重現規則中的詞語模式。錯分句也顯示語境的重要性。「我也是人，他们想要吃我了！」既像具體事件，也帶有象徵性的恐懼；短句和帶評價的長句同樣可能需要上下文才能判斷。加上人工與規則的一致率只有 82.76%，錯誤不一定全是模型造成，也可能是測試標籤本身有爭議。

在〈秋河〉的 111 句中，模型預測 67 句 abstract、44 句 concrete。99 句有非零字元特徵，覆蓋率比詞彙模型好；但 105 句的 `prob_concrete` 介乎 0.4 和 0.6，平均值和中位數也都接近 0.5。換句話說，模型雖然給了分類結果，多數句子的把握其實不高。例如，它把「東面靠牆，在牀與窗口桌子之間，有一個衣廚……」判為 abstract（0.4990），把「但她覺得這些男人，都不過是肉做的機械。」判為 concrete（0.5275）。這些預測值得回頭細讀，但〈秋河〉沒有人工金標，我無法知道它們判得對不對，也不能用這批結果證明模型能跨作者泛化。

限制與改進

最大的限制不是模型種類，而是資料怎麼切分。本研究只用魯迅的作品訓練，而且以句子隨機分 train 和 test；同一篇中的句子可能同時出現在兩邊。〈狂人日記〉偏心理與象徵、〈社戲〉有較多場景描寫，〈阿Q正傳〉又遠長於其他篇目，模型可能學到篇目特有的用詞或比例，而不是真正可移用的抽象 / 具體特徵。因此 0.7562 只能說明模型在這次隨機切分中表現如何，不能代表遇到新作者或新作品時也有同樣效果。字元 n-gram 改善了特徵覆蓋，卻沒有消除這種篇目線索。

標籤本身也有不確定性：關鍵詞規則不擅長處理語境、多義詞和否定，二元標籤又無法表示一句話同時有兩種特徵。人工一致率低於 85% 的參考門檻，提醒我不應只靠擴大詞表來追求更高分數。若繼續做，我會先請第二位標註者獨立判斷一批句子，討論分歧並修訂標註準則；接著按篇目留出測試集，看看模型是否只是認出篇目風格。對〈秋河〉則需要先建立人工標註，才有辦法評估跨作者表現。與其急著換更複雜的模型，這些步驟更能回答目前結果到底有沒有意義。

這次的 0.7562 看起來不差，但我認為它更像是下一步研究的起點，而不是結論。測試標籤與模型都受規則影響，句子隨機切分也可能讓同篇風格同時出現在訓練和測試資料中。對我來說，模型目前最實際的用途，是整理出需要重新閱讀的句子，而不是替句子作最後判決。若要主張它真的學會了跨作品的具體 / 抽象差異，還需要更可靠的人工標註和按篇目留出的測試。